

第八届中国研究生人工智能创新大赛

eZScholar 智能学术检索 Agent

项目文档

V1.0

研迹 ScholarTrace

企业赛题-科研场景下复杂学术查询的智能论文搜索与推荐

目录

一、 项目概况.....	1
(一) 背景和基础	1
(二) 场景和价值	3
(三) 所需支持.....	4
二、 项目规划.....	5
(一) 整体目标.....	5
(二) 技术创新点	6
三、 实施方案.....	9
(一) 技术可行性分析	9
(二) 技术细节.....	9
(三) 任务实施计划和风险分析	21
四、 参考资料.....	22

记录更改历史

序号	更改原因	版本	作者	更改日期	备注

一、项目概况

(一) 背景和基础

1. 项目背景与问题定义

本项目面向第八届中国研究生人工智能创新大赛“企业赛题-科研场景下复杂学术查询的智能论文搜索与推荐”，研发 **eZScholar 智能学术检索 Agent**（以下简称 **eZScholar**）。赛题要求系统能够理解复杂学术查询，自主完成检索与必要的迭代搜索，对候选论文进行综合排序，并以结构化形式返回高质量结果；评测同时考察检索质量、运行效率与结构化输出。因此，eZScholar 将任务建模为一个同时受**语义理解**、**候选覆盖**、**排序质量**、**执行成本**与**结果可复现性**约束的端到端科研信息检索问题。其中，“候选覆盖”是指与问题相关的目标论文能否在召回阶段进入后续筛选和排序所使用的候选集合，而不是将大语言模型简单封装为关键词生成器或通用问答接口。

为避免评测术语影响正文可读性，本文统一将基准数据中由人工标注的正确论文称为**真值论文 (Gold papers)**，后文简称“真值论文”；将用于确认评测数据版本未发生变化的摘要标识称为**评测语料版本指纹 (corpus fingerprint)**，后文简称“语料版本指纹”。对于系统内部对象，仅在首次出现时给出英文术语或缩写，后续优先使用中文通用表述。

科研用户提出的真实问题通常具有明显的组合性。例如，一个自然语言长查询可能同时限定研究对象、方法范式、数据集、评测指标、时间范围、应用环境与对比基线。若直接将完整长句提交给传统学术搜索引擎，查询中的多个约束往往无法被同时保留；若仅人工拆分关键词，又容易造成术语漂移与检索意图损失。赛题材料将 PaSa 与 AstaBench 列为参考数据/评测资源，其中 PaSa 发布的 RealScholarQuery 由 50 条真实、细粒度科研查询构成，用于评估复杂学术论文搜索系统在真实研究问题上的检索能力 [1, 11, 12]。本项目已实际使用 RealScholarQuery 开展全量历史验证与当前冻结子集验证，而不是仅以自构造示例展示系统功能。结合该基准的查询特征，本项目将主要困难归纳为以下四类：

- **语义复合与约束耦合**：单个问题同时包含多个研究侧面，不同侧面在论文标题与摘要中的显式程度并不一致；
- **用户措辞与学术术语错配**：用户可能使用任务描述、口语化表达或上位概念，而目标论文使用具体模型名、数据集名、评测基准名称或其他领域专有名称；
- **候选覆盖与排序相互制约**：精排器只能在已召回候选中工作，若目标论文没有进入候选池，继续增加排序复杂度无法恢复缺失论文；
- **结果可信与工程成本并存**：科研场景要求标题、作者、年份、DOI 等事实字段可核验，同时学术检索应用程序接口 (Application Programming Interface, API)、模型调用、模型词元 (Token，即模型处理文本时使用的基本计量单位) 消耗与时延必须受到预算约束。

基于上述问题，本项目采用“先形成可执行查询，再扩大有效候选覆盖，最后完成语义

精排与结构化解释”的总体思路。大语言模型 (Large Language Model, LLM) 主要负责查询理解、查询规划、候选相关性判断与结果归纳；论文身份与基础元数据由 OpenAlex 等学术数据源提供。该职责划分避免让生成模型承担论文事实生成任务，使系统能够在利用大模型语义能力的同时保持论文身份可追溯。

为统一竞赛文档、系统前端与后续科研应用中的视觉识别，项目采用“研迹 ScholarTrace”视觉标识，如图 1 所示。标识以“研迹”与 ScholarTrace 的中英文组合为核心，将科研工作中“论文阅读—知识记录—证据追踪—关系连接”的连续过程凝练为统一品牌形象；其中，“研迹”强调对研究线索与学术证据的持续记录，“ScholarTrace”对应对论文来源、检索路径与知识关联的可追溯表达。该视觉标识与 eZScholar 的技术目标保持一致，即不仅返回论文结果，还保留论文身份、来源查询和检索执行轨迹，使复杂学术检索过程能够被复核与追踪。



图 1 研迹 ScholarTrace 项目视觉标识。

2. 赛题要求与技术问题映射

赛题对查询理解、检索迭代、综合排序、结构化输出和运行效率的要求，在系统中分别对应可独立观测的工程模块。查询解析器首先将原始问题映射为**查询中间表示 (Query Intermediate Representation, QueryIR)**；查询规划器 (Planner) 据此生成常规子查询以及模型名、数据集名等具体学术名称补充查询；检索器 (Retriever) 执行论文召回 (retrieval，即从学术数据源获取候选论文) 并形成候选池 (即进入后续筛选与排序的论文集合)；论文身份模块完成去重与跨版本归一化 (即把同一学术成果的不同记录合并为统一论文实体)；精排器 (Reranker) 执行精排 (reranking，即对已召回候选进行更细粒度的相关性排序)，综合判断候选论文与原始科研问题的语义相关性。DEEP 模式进一步读取第一轮真实检索结果，形成**检索观察 (SearchObservation)** 并生成第二轮后续查询。最终，系统通过**结构化结果对象 (StructuredResult)** 输出论文信息，并通过**检索执行轨迹 (SearchTrace)** 记录查询、检索、排序与成本信息。

这种模块化设计的直接价值在于：检索质量下降时，可以区分问题发生在查询规划、原始召回、候选筛选还是精排阶段；运行效率下降时，可以定位具体 API、模型调用和 Token 消耗；结构化输出异常时，可以通过结构化数据模式 (Schema) 校验独立发现，而无需将所有问题混合为单一端到端黑盒指标。

3. 已有工作基础与工程积累

团队此前已完成过工程可信智能体系统，并将其中的结构化中间表示、约束解析、多路候选获取、候选筛选、证据追踪、工具编排、缓存与异常处理等经验迁移到学术检索场景，形成 eZScholar 原型。经过多轮受控实验与系统收口，当前工程已具备以下基础：

- 以查询中间表示、子查询、论文身份、检索观察、检索执行轨迹和排序结果等结构化对象贯通查询、检索、候选、迭代与输出阶段；
- 支持复杂查询解析、保留式扩展查询规划、OpenAlex 学术召回、论文身份归一化、候选池构建和大语言模型综合精排；
- 支持快速单轮模式（FAST）与深度迭代模式（DEEP）两种运行模式，其中 DEEP 在第一轮真实论文证据基础上识别未覆盖约束、新实体与术语，并执行第二轮后续检索；
- 通过冻结查询计划（即固定评测所用查询计划后不再自动改写）、响应缓存、提示词与配置版本哈希（hash，用于唯一标识配置内容）、语料版本指纹，以及“禁止静默回退”（关键计划或缓存缺失时直接报错而非自动改走其他路径）机制保证离线评测条件稳定；
- 建立阶段级检索执行轨迹与真值论文命中生命周期统计，同时记录候选增量、真值论文命中、逻辑接口调用（按程序发起的检索操作计数）与物理网络请求（实际访问外部服务的超文本传输协议 [Hypertext Transfer Protocol, HTTP] 请求）、模型调用和 Token 消耗；
- 已完成统一命令行接口、离线缓存重放（cache replay，即在不重新访问外部接口的情况下复用已保存响应重现同一执行链路）、结构化输出校验、**真值信息泄漏检测（Gold leakage test）**和自动化测试，为比赛复现与提交审计提供工程基础。

需要说明的是，受控研发实验曾对引文扩展、多源召回（即从多个学术数据源获取合并候选论文）、不同精排器和多轮检索进行多组实验。本文不按内部试验顺序罗列全部试错，而仅保留能够解释最终系统设计选择的受控证据；历史实验口径与正式冻结评测（即固定查询集、真值论文集、关键配置与缓存后不再改变评测条件）的口径严格区分，避免将不同数据版本或不同候选池上的结果直接比较。

（二）场景和价值

1. 典型应用场景

eZScholar 主要面向学生、研究生及科研工作人员，其目标并非替代研究者完成学术判断，而是降低“问题表达—检索改写—结果筛选—证据整理”这一高频工作流的机械成本。典型场景包括：

- **陌生方向调研**：用户以自然语言描述研究问题，系统自动拆解研究主题、方法与约束，返回代表性论文与可继续追踪的学术术语；
- **相关工作检索**：围绕具体模型、方法、数据集或评测基准进行细粒度论文发现，减少

人工反复改写关键词的工作量；

- **交叉领域探索**：面对同时涉及多个研究领域或多个约束的复杂问题，通过多查询组合提高候选覆盖，并保留每篇论文的召回来源；
- **文献整理与证据追踪**：将论文身份、相关性解释、来源查询与检索执行轨迹一并保存，为后续综述、立项与研究复盘提供可追溯依据；
- **复杂问题深度检索**：当第一轮结果暴露新的模型、数据集、评测基准名称或领域术语时，DEEP 模式能够基于真实检索证据继续生成后续查询，形成二轮自主检索闭环。

2. 项目价值

项目价值体现在科研效率、结果可信和工程复用三个层面。首先，系统将传统“人工拆词—多次搜索—逐篇筛选”的串行流程转化为结构化查询规划与自动检索，降低复杂问题的搜索门槛。其次，系统明确区分**语义推理与学术事实**：大语言模型负责理解和排序，标题、作者、年份、DOI、OpenAlex ID 等事实字段来自学术数据源，从设计上降低论文身份幻觉风险。最后，检索执行轨迹将检索效果与执行成本置于同一观测框架中，使每次搜索都能够回答“用了哪些查询、调用了哪些接口、为何继续搜索、最终论文从何而来”，这为竞赛复现、失败归因和后续产品化提供统一工程基础。

从应用延展角度看，eZScholar 的核心资产不是单一“论文搜索页面”，而是一套可复用的科研检索引擎（Research Engine）：复杂查询被转换为结构化搜索计划，候选论文经身份归一化后进入语义排序，并可进一步形成项目库、科研收件箱（Research Inbox）、证据卡片与持续文献跟踪等科研工作流能力。因此，竞赛版本重点验证检索与可审计执行链路，后续产品化可在不改变核心论文身份与搜索逻辑的前提下扩展移动端保存、同步与长期跟踪能力。

（三）所需支持

项目不依赖自建大规模论文全文库，主要资源由开放学术检索接口、大语言模型推理接口、常规计算环境、缓存存储与稳定网络组成。正式生产召回以 OpenAlex 为主；Semantic Scholar 在当前版本中用于多源召回诊断，不作为默认生产链路。模型侧采用 DeepSeek API 承担查询规划与候选语义判断，当前冻结配置记录的模型标识为 `deepseek-chat`；若提交环境锁定到更具体的服务版本，则以最终配置清单与运行日志中的模型标识为准。离线评测通过冻结计划和响应缓存避免重复消耗外部配额。

表 1 项目实施所需支持

支持类别	主要内容	用途
学术数据接口	OpenAlex 等开放学术检索接口	论文召回、论文身份及基础元数据获取
模型推理能力	DeepSeek 大语言模型 API	复杂问题理解、查询规划、候选语义判断
计算与存储	常规 CPU 服务器或个人计算机、实验缓存空间	运行检索流程、保存响应缓存与评测产物
开发环境	Python 3.13.5 及版本管理、自动化测试工具	系统开发、评测与实验复现
网络环境	稳定的外部 API 访问能力	在线学术检索和模型调用

二、项目规划

（一）整体目标

项目总体目标是构建一个面向科研场景的复杂学术查询智能搜索与推荐系统，通过“查询理解 → 查询规划 → 学术召回 → 身份归一化 → 候选筛选 → 语义精排 → 可选迭代搜索 → 结构化输出”的完整链路，将复杂自然语言问题转化为高质量、可追溯、可复现的论文检索结果。

围绕赛题评分维度，系统目标被拆分为三个相互约束的工程指标：其一，检索质量以最终用户可见结果的精确率（Precision）、召回率（Recall）与 F1 值为主，同时分别记录原始召回阶段、精排候选池阶段和最终输出阶段的真值论文命中，避免不同阶段的命中数量混用；其二，运行效率同时记录学术接口调用、大语言模型调用、Token 消耗与时延，并明确区分**离线缓存重放（cache replay，即复用已保存响应重现同一执行链路）**与真实网络环境的执行成本；其三，结构化输出采用统一的数据模式（Schema），使论文身份、相关性解释、召回轮次和来源查询能够被程序校验并直接供前端渲染。

表 2 赛题评测维度与系统设计对应关系

评测维度	权重	系统设计重点
检索质量 (F1)	70%	查询理解、保留式扩展查询规划、候选覆盖、语义精排与必要的二轮检索
运行效率	20%	缓存复用、重复查询过滤、调用预算、低收益阶段裁剪与 FAST/DEEP 双模
结构化输出	10%	统一结构化结果对象、论文身份归一化、相关性解释与检索执行轨迹

系统正式保留 FAST 与 DEEP 两种运行模式。FAST 作为默认竞赛评测路径，优先保证质量、效率与稳定性；DEEP 在 FAST 第一轮基础上加入证据分析与后续检索，用于复杂问题的深度搜索和自主迭代能力展示。

表 3 FAST 与 DEEP 双模式定位

模式	主要流程	定位
FAST	查询规划 → OpenAlex 召回 → 去重与候选池 → LLM 精排 → 结构化输出	默认竞赛评测模式，优先保证质量、效率与稳定性
DEEP	FAST 第一轮 + 检索观察 → 二轮查询规划 → 后续检索 → 候选合并 → 精排	复杂问题的可选深度检索与自主迭代搜索模式

(二) 技术创新点

1. 面向复杂查询的保留式扩展查询规划

复杂学术查询的首要困难不是“生成更多关键词”，而是如何在破坏已有有效检索表达的前提下补充模型名、数据集名等具体学术名称，并通过同义表达或相关研究概念连接用户措辞与论文术语。系统因此采用**保留式扩展查询规划**：原始有效子查询始终保留，查询规划器只追加与研究主题、方法、模型、数据集或评测基准相关的补充查询。对于由联想词或具体学术名称查询召回的候选，系统设置**联想词候选保留机制 (assoc safepass)**，即让这类候选跳过仅依赖用词重叠的低成本初筛，避免高价值论文因与原始长句用词不同而被提前排除。

受控实验显示，直接用新计划替换稀疏原计划并不能提高真值论文覆盖，而“保留原查询 + 追加补充查询”使原始召回阶段去重后的真值论文数由 22 提升至 25，平均 F1 提升至 0.0664。进一步关闭联想词候选保留机制后，进入精排候选池的真值论文数量明显下降，说明该机制的主要作用不是制造额外召回，而是保护已由具体学术名称查询发现的候选能够进入后续语义判断阶段。

表 4 查询公式化与证据引导迭代检索的召回增益

优化环节	策略	去重真值论文数	增量
查询公式化	初始查询组合	22	—
	追加联想词/具体学术名称子查询	25	+3
	单次提示词修订后的诊断结果	26	+1
证据引导迭代检索	单轮检索	25	—
	合并两轮检索	27	+2 (2/22 查询)

表 4 汇总了查询公式化与二轮检索对候选覆盖的影响。需要强调的是，表中“26 篇”来自提示词修订后的诊断性实验，其最终 F1 并未同步提升，因此系统没有继续围绕提示词进行反复调参；正式工程选择更稳定的“保留原查询并追加补充查询”策略。该结果说明，eZScholar 的查询规划优化目标不是无限增加查询数量，而是在保持已有有效表达的同时，提高具体学术名称与同义术语改写的命中概率。

2. 基于边际收益的检索预算重分配

系统通过阶段级检索执行轨迹记录每个检索阶段的逻辑调用、候选增量与真值论文命中，并据此评估不同扩展策略的边际收益。在历史受控实验中，引文、参考与元数据扩展合计消耗 422 次逻辑调用，却没有带来新增真值论文；关闭这些低收益扩展后，逻辑调用由 511 降至 87，平均 F1 由 0.0528 提升至 0.0618。该结果表明，在当前评测集与配置下，预算应优先投入查询规划、直接检索和必要的语义判断，而不是无差别扩大引文图。

表 5 低收益扩展阶段的受控消融

方案	平均 F1	逻辑 API 调用	实验结论
完整扩展链路	0.0528	511	引文、参考与元数据扩展占用大量调用，未新增真值论文
关闭低收益扩展	0.0618	87	成本显著下降，F1 未受损并有所提升

3. 证据引导的二轮自主检索

DEEP 模式并非在原问题上简单“再生成一批查询”，而是在第一轮检索后构造检索观察，读取真实返回论文中的标题、摘要与主题信息，识别已覆盖约束、未覆盖约束以及新出现的方法、模型、数据集或术语，再生成少量第二轮后续查询。由此形成“检索 → 观察 → 分析 → 再检索”的闭环。

冻结实验中，二轮检索将原始召回阶段去重后的真值论文数由 25 提升至 27，并产生了可完整追溯的“第一轮论文证据 → 新实体/术语 → 后续查询 → 新论文”案例，验证了自主迭代机制的可行性；但 62 个实际后续查询仅新增 2 篇真值论文，边际收益不足以支持所有查询默认执行第二轮。因此，最终系统将 FAST 设为默认模式，将 DEEP 保留为面向复杂问题的可选深度搜索能力。这一设计把“是否继续搜索”从展示性功能转化为质量与成本之间的明确工程权衡。

4. 统一论文身份与可审计执行轨迹

系统以 DOI、OpenAlex ID、arXiv 标识与规范化标题构建统一的**论文身份对象 (PaperIdentity)**，解决同一论文在期刊版、预印本或不同数据源中重复出现的问题。检索执行轨迹记录原始问题、查询规划版本、生成查询、学术接口调用、候选数量、二轮决策、精排调用、最终论文与运行时延。冻结查询计划、响应缓存、提示词与配置版本哈希以及“禁止静默回退”机制共同保证离线重放的一致性。

与仅输出论文列表的检索系统相比，该设计将“结果为什么出现”与“系统为此付出了多少成本”同时纳入结果证据。它既服务于比赛复现，也支持失败归因：当某篇目标论文未进入最终结果时，可以区分其是否未被召回、在候选筛选阶段被排除，或在精排阶段被降级。

5. 与现有科研检索工具及参考系统的差异

当前科研检索工具已经覆盖关键词检索、论文推荐、引文网络、自动总结乃至多步 Research Agent 等多种能力，因此 eZScholar 的差异不能简单表述为“能够用大模型搜论文”或“能够进行多轮搜索”。例如，Semantic Scholar 已提供大规模论文搜索、TLDR、影响力引文、Research Feed 与 Alerts 等能力 [14]；ResearchRabbit 强调论文、作者和概念之间的可视化连接与基于探索行为的推荐 [15]；Consensus 的 Research Agent 已公开支持多步子搜索、引文追踪、DOI/作者检索、相似论文与上下文连续研究，并可在 Deep Review 中执行多次定向搜索 [16, 17]；Elicit 则将论文搜索、系统综述、筛选、证据提取与可追溯研究工作流进一步整合 [18]。这些系统说明，“查询分解”“多轮搜索”“引用追踪”本身已经不是足以单独构成差异化的功能。

因此，本项目将比较维度从“功能是否存在”调整为“**系统是否围绕赛题的质量—成本—结构化输出目标形成可测、可复现的联合优化闭环**”。表 6 对公开产品与研究系统的主要定位进行概括。表中的“非公开核心目标”不表示对应系统绝对不具备该能力，而是指其公开产品说明或论文并未将该能力作为与本项目相同的主要评测/工程目标，避免对商业系统内部实现作未经证实的推断。

表 6 eZScholar 与代表性科研检索工具/系统的定位差异

系统	公开核心定位	代表性能力	与 eZScholar 的主要差异
Semantic Scholar	通用学术搜索与持续发现	大规模论文搜索、TLDR、影响力引文、Research Feed、Alerts	更偏通用检索、推荐与持续发现；eZScholar 聚焦复杂长查询的可执行化、阶段级成本记录和赛题指标闭环
ResearchRabbit	文献关系探索与可视化发现	相似论文推荐、论文/作者/概念关系图、Collections	更强调从种子论文向关系网络探索；eZScholar 以自然语言复杂查询为起点，并显式评测召回、精排和成本
Consensus	面向科研问题的多步 Research Agent	子问题规划、定向搜索、引文追踪、DOI/作者/相似论文检索、结构化综合	已具备成熟多工具研究能力；eZScholar 不以功能数量竞争，而强调受限 API/Token 预算下的阶段级收益测量、失败归因和可复现评测
Elicit	证据综合与系统综述工作流	论文搜索、筛选、证据提取、报告/系统综述、可追溯研究过程	更偏完整证据综合与高价值研究工作流；eZScholar 当前聚焦论文发现阶段，并把 F1、调用成本和结构化输出作为同一优化目标
PaSa	复杂学术论文搜索 Agent	Crawler+Selector 双 Agent、自主工具调用、论文阅读与引用扩展、强化学习优化	PaSa 通过训练/RL 提升复杂检索能力；eZScholar 采用外部 LLM+ 开放 API 的轻量工程路线，强调冻结计划、预算裁剪、论文身份归一化与 SearchTrace
AstaBench / PaperFindingBench	科研 Agent 标准化评测	以自然语言描述寻找论文集合，并同时记录性能与计算效率	属于评测框架而非直接竞品；当前项目将其作为后续外部标准化验证资源，不把尚未完成的结果写入当前成绩
eZScholar	受限预算下的复杂学术查询检索	保留式查询扩展、证据引导二轮检索、阶段级失败归因、统一论文身份、SearchTrace、FAST/DEEP	核心贡献是把“搜得准、花多少、为何失败、能否复现”放入同一可审计工程闭环，并直接对应赛题评测维度

在研究型参考系统中，PaSa 是与本项目任务最接近的对照。PaSa 采用 Crawler 与 Selector 双 Agent，并通过强化学习在合成数据上训练，RealScholarQuery 用于真实复杂查询评测 [1, 11]。eZScholar 不声称在模型训练规模或公开基准绝对性能上超越 PaSa，而是选择不同的工程问题：在不训练专用 7B Agent 的条件下，利用开放学术 API 与通用大语言模型构建可复现检索链路，并通过阶段级实验回答“预算应该花在哪一层”。例如，当前受控实验发现引文/参考/元数据扩展消耗 422 次逻辑调用却未新增真值论文，因此将其从默认路径裁剪；查询公式化与候选保护则能够提高真值论文进入候选池的概率。这种设计

使 eZScholar 的差异落在**质量—成本联合优化、失败生命周期归因和执行轨迹审计**，而不是重复已有工具已经具备的多轮搜索功能。

从赛题竞争角度，本项目现阶段最重要的优势并不是宣称“功能更多”，而是能够把一次复杂检索拆成可验证的证据链：**原始问题** → **QueryIR** → **子查询** → **候选论文** → **身份归一化** → **筛选/精排** → **最终结果** → **API/Token/时延**。当 F1 下降时，系统能够进一步判断真值论文是未被召回、在轻量筛选中丢失，还是在精排中未被保留。该能力直接服务于赛题的 F1 与效率优化，也为后续隐藏测试中的问题定位提供工程基础。

三、实施方案

（一）技术可行性分析

从**数据条件**看，OpenAlex 提供覆盖广泛的学术论文元数据与检索接口，可满足基础论文搜索、身份核验与候选获取需求；系统无需自建全文索引，降低了存储、索引构建与持续维护成本。当前正式生产召回以 OpenAlex 为主，多源诊断表明 Semantic Scholar 对部分查询具有互补召回能力，但该能力尚未合入正式生产路径，因此本文仅将其作为后续多源候选融合的诊断依据。

从**算法条件**看，复杂学术查询可以分解为查询理解、检索规划、候选召回、身份归一化、候选池构建、语义精排与结果整理等相对独立的环节。大语言模型负责固定规则难以完成的语义理解与相关性判断，学术数据接口负责论文事实与候选集合，职责边界清晰。系统已通过查询规划、预算裁剪、精排器对照和二轮检索等受控实验验证主要模块的必要性与局限性。

从**工程条件**看，系统已完成 FAST/DEEP 统一检索引擎、结构化输出、检索执行轨迹、冻结查询计划与响应缓存、真值信息泄漏检测及自动化测试。当前正式评测语料固定为 22 条复杂查询、184 篇按论文去重的真值论文，并以语料版本指纹固化版本；离线缓存重放在缺失冻结计划或缓存时显式报错，避免静默回退导致实验条件变化。

从**效率条件**看，阶段级诊断已证明低收益扩展可以被移除，第二轮检索设置了最大 66 次新检索预算，冻结执行中实际完成 62 次后续查询。离线效率报告同时记录 LLM 调用、Token、候选规模与时延，并与真实在线 HTTP 成本分开统计，为比赛的运行效率评分提供可核验依据。

（二）技术细节

1. 系统总体架构

图 2 展示了 eZScholar 的“先宽后窄”检索闭环。复杂自然语言查询先被解析为结构化检索要素，再由查询规划器生成不超过 5 个高优先级子查询；候选获取层预留 OpenAlex 与 Semantic Scholar 的多源召回能力，随后以词法粗筛（根据标题、摘要与查询之间的词语匹配进行低成本初筛）将候选压缩至 Top-40，再交由大语言模型完成综合精排、约束覆盖

判断与动态截断（根据相关性判断确定最终保留的候选数量）。对于仍需扩展的查询，系统读取第一轮真实论文的标题、摘要与主题信息形成检索观察，并据此生成少量后续查询回到检索规划环节；引文/参考扩展在历史实验中因边际收益较低已从默认竞赛路径移除。最终系统输出结构化推荐结果、F1 评测信息与可追溯证据。




图 2 eZScholar “先宽后窄”检索闭环：查询解析与高优子查询规划、学术候选召回、Top-40 词法粗筛、大语言模型综合精排，以及由第一轮真实检索证据触发的可选迭代检索。

表 7 受控对照实验与赛题功能点的对应关系

对照设置	功能定位	对应能力
词法检索基线	原始查询直接检索 OpenAlex，并采用词法相关性排序	检索能力下限对照
查询理解与子查询分解	查询中间表示、子查询分解、联想词/具体学术名称补充	查询理解与查询改写
引文与元数据扩展	对候选论文执行引文、参考及元数据扩展	自主检索迭代的历史对照
大语言模型综合精排	基于原始科研问题对候选进行语义相关性判断	论文综合排序
缓存与预算控制	响应缓存、调用预算、低收益阶段裁剪	运行效率与稳定性
完整检索链路	查询规划、召回、精排、结构化归纳与可选迭代检索	赛题全链路能力

2. 查询理解与规划

查询解析器将原始自然语言问题映射为查询中间表示，显式表示研究主题、方法、应用场景、约束条件和年份范围等检索要素。查询规划器在此基础上生成可执行子查询，并将查询划分为常规检索表达、模型名、数据集名等具体学术名称补充表达，以及用于连接不同学术表述的语义改写表达。FAST 模式对常规子查询数量设置上限，联想词与具体学术名称查

询独立执行；DEEP 模式则在第一轮真实检索结果基础上生成少量第二轮后续查询。

查询规划阶段强调两个工程约束。第一，补充查询不能覆盖或替换已经验证有效的原始表达，避免“优化”导致已有召回丢失；第二，新实体必须能够追溯到原问题或第一轮真实证据，禁止根据真值论文标题、作者、DOI 等评测信息反向构造查询。查询规划器版本、提示词和关键配置均通过版本哈希（hash）固化，评测时禁止逐查询观察真值信息后再修改提示词。

3. 论文召回、身份归一化与缓存

正式召回源为 OpenAlex，单次检索返回前 20 条候选（Top-20）。不同子查询返回的候选首先进入统一身份层，以 DOI、OpenAlex ID、arXiv 标识和规范化标题执行去重与归一化。对于期刊版/预印本等可能存在多个记录的论文，系统优先通过稳定身份字段合并，避免同一学术成果在候选池和评测中被重复计数。

计划缓存与召回缓存相互独立：前者保存查询到结构化计划的映射，后者保存具体学术检索请求与响应。该设计使查询规划、检索和精排模块能够在受控条件下分别评估。离线缓存重放仅允许读取冻结计划和缓存，缺失时显式失败，不允许自动重新调用查询规划器或学术接口，从而保证同一实验的候选池和执行条件可复现。

4. 候选筛选与综合精排

候选池首先执行轻量词法相关性过滤（即依据标题、摘要与查询之间的词语匹配进行低成本初筛），同时启用联想词候选保留机制，随后由大语言模型综合判断候选与原始科研问题之间的语义相关性。精排输入以原始研究问题为语义基准，候选侧使用论文标题与可用摘要；输出包含相关度评分和解释，并在统一排序后形成最终结果。

为验证生成式精排是否可以被更稳定、成本更低的方法替代，项目在冻结候选池上对倒数排名融合（Reciprocal Rank Fusion, RRF）、MiniLM Cross-Encoder 与 BGE reranker v2-m3 进行了受控比较。结果如表 8 所示：当前配置下 LLM 综合精排获得最高最终 F1，但重复运行显示其存在一定随机性；确定性模型具有稳定性优势，却未达到相同的总体排序质量。因此，正式系统暂时保留 LLM 精排，并依靠冻结结果与缓存重放保证比赛离线复现。

表 8 冻结候选池上的精排方法对照

精排策略	类型	模型规模	宏平均 F1
大语言模型综合精排	生成式	—	0.0664
MiniLM Cross-Encoder	轻量语义精排	22M	0.0598
BGE reranker v2-m3	专用语义精排	约 0.6B	0.0588
RRF	无模型融合	—	0.0241

图 3 展示了生成式精排在相同候选输入下仍可能产生排序波动。图中每个查询均在完全一致的冻结候选池上重复执行 3 次精排；Q15 的最高与最低 F1 相差 0.089，Q6 也出现可见波动，而其余查询相对稳定。这表明当前大语言模型精排的主要风险不是候选集合变




图 3 大语言模型精排稳定性对照。对 7 条高覆盖查询在相同冻结候选池上重复精排，部分查询的 F1 出现波动，最大差值为 0.089，表明生成式精排存在非确定性。

化，而是生成式评分本身存在非确定性，因此正式离线评测需要通过冻结排序结果和缓存重放控制随机波动。

5. 预算控制与低收益阶段裁剪

eZScholar 将运行成本作为检索链路的一等指标，而不是在算法完成后再进行被动压缩。每次运行记录逻辑 API 调用、物理 HTTP 请求、缓存命中、查询规划/精排模型调用、Token 与时延。历史受控实验表明，引文、参考和元数据扩展在当前评测集上消耗大量逻辑调用却没有增加真值论文，因此这些阶段被从默认路径移除。DEEP 的二轮检索进一步设置后续查询数量与总预算上限，并对重复查询进行过滤，避免自主搜索演化为无界 API 消耗。

这种预算机制使 FAST 与 DEEP 形成清晰分工：FAST 适合作为默认竞赛评测模式；DEEP 仅在需要展示或执行更深入的证据引导搜索时使用。二者共享同一论文身份、精排和输出层，因此模式差异主要体现在检索深度，而不是两套不可比较的系统实现。

6. 证据引导的二轮检索

DEEP 在第一轮检索后选取真实返回论文构造检索观察，向二轮查询规划器提供标题、摘要和主题等可用证据。规划器先判断原问题中的哪些约束已经被覆盖，再识别未覆盖条件以及检索证据中出现的新实体和领域术语，最终生成面向“约束缺口、实体追踪、术语桥接”的三类后续查询。每个新实体必须记录来源论文和来源字段，不可追溯实体不允许进入检索表达。

这一机制的意义在于把“多轮检索”从固定流程改造成基于已观察证据的决策过程。以冻结实验中的真实案例为例，第一轮论文证据暴露了 Lean 实体，系统随后形成“Lean formal

proof generation LLM” 查询，并在第二轮发现第一轮不存在的 DeepSeek-Prover。该案例说明 eZScholar 能够利用检索结果改变后续搜索方向；与此同时，整体增益仅为 2 篇新增真值论文/62 个后续查询，因此本文将其作为机制有效、规模化收益仍需优化的工程能力，而不夸大为全面提升最终 F1 的策略。

7. 结构化输出与检索执行轨迹

系统最终输出统一的结构化结果对象。论文事实字段包括规范化论文标识、标题、作者、年份、来源、DOI 与 OpenAlex ID；相关性字段包括相关度评分、相关性解释、召回轮次与来源查询。事实字段来自学术数据源，大语言模型不负责生成论文标题、作者、DOI 等身份事实。检索执行轨迹同步记录原始问题、查询规划器版本、生成查询、检索调用、候选数量、二轮决策、后续查询、精排调用、最终论文与运行时延。

该输出设计同时服务于评测与前端：评测程序可以直接校验结构化数据模式和论文身份，前端则可以在不重新解释模型文本的情况下展示论文卡片、主题归纳、执行成本与检索来源。由此，系统的“可解释性”不依赖额外生成一段自然语言说明，而是由结构化字段和执行轨迹共同提供。

8. 前端展示与人机交互实现

为验证后端科研检索引擎在真实科研检索 workflows 中的可用性，eZScholar 实现了轻量 Web 前端，并将交互层划分为**查询入口**、**结果解释与评测仪表板**三个相互衔接的界面。前端仅消费后端结构化结果对象与检索执行轨迹，不在浏览器侧重新生成论文事实或改写检索结果，从而保证比赛评测、在线演示与离线复现使用同一套论文身份、排序结果和成本统计口径。

图 4 展示了 eZScholar 的查询入口及任务配置方式。主区域以“您想探索什么研究课题？”作为任务引导，面向长句复杂科研问题提供自然语言输入框；输入区下方可选择 FULL（全链路演示模式，用于展示完整检索流程）等运行链路，并通过“深度归纳”开关控制是否生成更完整的研究主题归纳。右侧“搜索”按钮用于启动检索任务，页面下方的 Ready 状态表示当前服务可接受新的查询请求。左侧导航提供“查询”和“仪表板”入口并保留近期检索记录。该页面将复杂查询、运行链路和服务状态集中到单一入口，降低用户在多个配置页面之间切换的操作成本。

图 5 展示了 eZScholar 如何把一次检索的结果、归纳信息与执行成本组织在同一页面。示例查询为“point cloud deep learning”，截图中的 B0 表示词法基线模式（Baseline 0，用于与完整检索链路进行对照）。搜索框下方依次展示命中文献数、LLM 调用次数、Token 消耗、墙钟耗时（wall-clock time，即用户实际等待的自然时间）以及检索轮次/数据源等运行摘要；截图示例中显示命中 20 篇、LLM 调用 1 次、消耗 1,917 Token、耗时 4,760.2 ms，并标记为第一轮 OpenAlex 检索（R1:OPENALEX）；中部蓝色区域给出对结果集合的总体研究主题解释，并以标签聚合 Reviews and Surveys、Registration and Matching、Semantic Segmentation and Classification、Dynamic Point Clouds and Sequences 等主题及对应论文数量，使用户在逐篇阅读前先形成对候选集合的结构化认识。




图 4 eZScholar 查询入口界面。页面提供复杂科研问题输入、检索链路选择、深度归纳开关、服务状态与近期查询管理。


结果列表进一步以论文卡片形式展示排名、相关性等级、论文标题、相关度分值、作者、期刊/会议、年份与 OpenAlex 身份信息。卡片中的 title_hits 和 abs_hits 分别表示标题命中次数 (title hits) 与摘要命中次数 (abstract hits)，用于提示候选论文在不同文本字段中与检索表达发生匹配的程度。图 5 因而同时回答三个问题：**检索得到了什么、系统为何认为其相关、完成本次搜索付出了多少计算成本**。前端保留 B0、FULL 等演示/对照链路，正式竞赛指标仍以 FAST 与 DEEP 的冻结评测结果为准。

图 6 展示了 eZScholar 如何将正式冻结评测、运行成本和工程验收状态集中到同一仪表盘。页面顶部以 RealScholarQuery 冻结评测语料为统一口径，核心卡片显示 FAST F1=0.0680、DEEP F1=0.0641、DEEP 最终命中 15/184 篇真值论文、冻结查询数 22，以及结构化结果通过率 100%。中部“效能对比”表将 FAST 与 DEEP 的 LLM 调用总量、单查询调用、Token、平均时延、第 90 百分位时延 (P90) 以及候选文献均值与最终输出均值并列展示，用于直接观察深度检索带来的质量—成本变化。

页面下方的“本次会话”区域展示当前交互会话的查询次数、命中文献数和常用模式；“S2 门禁状态”是项目内部用于汇总提交前工程验收项的状态区，其中 CORPUS FROZEN、METRIC SEMANTICS、GOLD LEAKAGE、TESTS 22/22、FAST/DEEP SCHEMA、EFFICIENCY REPORT 与 STRUCTURED OUTPUT 分别对应评测语料冻结、指标语义一致、真值信息泄漏检测、自动化测试、双模式结构化数据校验、效率报告和结构化输出检查。该仪表盘直接映射冻结评测与工程验收产物，而非独立生成展示数据。界面中的 FAST 14.1 s、DEEP 22.0 s 来自离线缓存重放，主要用于比较两种模式的相对计算开销，不能等同于真实网络条件下 OpenAlex 与 DeepSeek 的生产时延。

9. 评测数据构建与论文身份对齐

为保证评测公正性与可复现性，系统对真值论文执行统一身份归一化。原始基准中的论文记录可能以标题、DOI 或不同版本出现，若直接以字符串比较会产生同一论文重复计数或同名论文误匹配。系统因此优先使用 OpenAlex ID 与 DOI，必要时辅以 arXiv 标识和



(a)

图 5 eZScholar 结构化查询结果界面。页面同步展示会话成本摘要、主题归纳与论文级排序结果，并保留论文身份和检索证据，便于科研用户快速筛选结果。

研究ScholarTrace

Q 查询SEARCH

品 库名称DASHBOARD

近期记录RECENT

22 Q 184 Gold

AUDITED

federated learning with di...
B3 20 篇

federated learning with di...
B3 20 篇

graph neural networks for...
B3 20 篇

vision language model inst...
B2 20 篇

graph neural networks for...
B4 20 篇

point cloud deep learning
B0 20 篇

point cloud deep learning
B0 20 篇

point cloud deep learning
B0 20 篇


point cloud deep learning
B0 20 篇

3D point cloud classifiati...
P0L 20 篇

point cloud deep learning
B0 9 篇

(b)

图 5 (Continued) eZScholar 结构化查询结果界面。页面同步展示会议成本摘要、主题归纳与论文级排序结果, 并保留论文身份和检索证据, 便于科研用户快速筛选结果。



规范化标题；标题归一化处理大小写、标点和空白差异，最终按论文实体进行集合匹配。

正式评测语料固定为 22 条复杂查询和 184 篇按论文去重的真值论文。系统为该评测语料生成版本指纹，用于验证查询集合、真值论文集合和评测文件在不同复现实验中保持一致。受控实验曾使用规模不同的历史子集或不同计数口径，这些结果仅用于受控实验，不与正式冻结评测结果直接混合比较。

10. 赛题参考数据集上的验证与失败归因

赛题材料明确将 PaSa 与 AstaBench 列为参考数据/评测资源。PaSa 发布的 RealScholarQuery 是由 50 条真实、细粒度科研查询组成的测试集，真值论文由专业标注者通过多种检索方式尽可能完整地确定 [1, 11]。因此，本项目在赛题参考资源对应的真实复杂查询基准上运行检索链路。当前证据分为两层：第一层是早期历史全链路对 RealScholarQuery 50 条查询的全量离线验证；第二层是当前最终 FAST/DEEP 工程在其中 22 条复杂查询、184 篇去重真值论文组成的冻结评测语料上的严格重放与效率审计。两层实验的配置和候选池不同，故不直接混合比较，但共同用于证明系统确实在赛题参考基准上执行过端到端检索，而不是只展示前端样例。

表 9 赛题参考评测资源与本项目当前验证覆盖

参考资源	与赛题任务的关系	eZScholar 当前验证情况	结论
PaSa / RealScholarQuery	50 条真实、细粒度复杂科研查询，用于论文集合检索评测	已完成历史 50 条全量离线实验；当前最终 FAST/DEEP 另在 22 条冻结子集、184 篇真值论文上完成严格评测	已有实测证据

表 10 RealScholarQuery 历史全量离线评测结果（OpenAlex 口径）

指标	词法基线	查询理解对照	历史全链路
平均 F1	0.0095	0.0127	0.0774
召回率 R	0.100	0.133	0.0950
F1 > 0 查询数	2/20	2/15	26/50
最高单条 F1	—	—	0.370

注：词法基线与查询理解对照受接口配额限制，分别覆盖 20 条和 15 条查询；历史全链路覆盖 RealScholarQuery 全部 50 条查询。该结果证明系统曾在赛题参考基准上执行完整检索，但由于其配置与当前最终 FAST/DEEP 不同，本文不把 0.0774 作为当前最终系统成绩，也不与 22 条冻结评测直接横向比较。

图 7 说明了历史全链路在不同复杂查询上的性能差异：50 条查询中有 26 条取得非零 F1，且少数查询可达到 0.30 以上，但仍有 24 条查询为零分。该分布表明系统并非在所有问题上均匀受限，而是存在明显的“可召回查询”和“未覆盖查询”分化，因此后续优化重点应优先放在扩大有效候选覆盖，而不是仅对已经命中的查询继续提高排序复杂度。

进一步对正式冻结评测中的 184 篇真值论文进行生命周期归因（即跟踪每篇真值论文在召回、筛选和精排各阶段的去向），可将未进入最终正确结果的原因定位到召回、轻量筛选和精排三个阶段。表 11 显示，162 篇真值论文在原始召回阶段即未进入候选池，占 88.0%；13 篇在轻量词法筛选阶段被排除，占 7.1%；




图 7 历史全链路在 RealScholarQuery 50 条复杂查询上的逐条 F1 分布。原提案实验显示 26 条查询取得非零 F1，最高单条 F1 为 0.370；其余查询的主要问题仍集中在候选覆盖不足。

9 篇在综合精排阶段未进入最终正确结果，占 4.9%。因此，当前系统的首要性能瓶颈是**候选覆盖**，而不是继续单独扩大精排模型规模。需要说明的是，该表描述的是真值论文的未命中去向，并不等价于系统不存在非真值候选。

表 11 真值论文未命中去向归因（22 条冻结查询、184 篇真值论文）

归因类别	篇数	占比	发生阶段
未进入候选池	162	88.0%	原始召回
轻量筛选阶段排除	13	7.1%	候选筛选
精排阶段未保留	9	4.9%	综合排序
合计	184	100%	—

11. 当前最终系统的冻结子集评测结果

FAST 与 DEEP 均以最终用户可见结果为口径计算 Precision、Recall 与 F1；原始召回阶段、精排候选池阶段和最终输出阶段的真值论文命中分别记录，避免不同生命周期指标混用。表 12 给出正式冻结评测结果。FAST 的平均 F1 为 0.0680，高于 DEEP 的 0.0641，因此默认竞赛路径采用 FAST；DEEP 虽然最终 F1 未提升，但最终结果中去重后的真值论文数为 15，高于 FAST 的 14，并保留了真实的二轮检索轨迹，适合作为复杂问题的深度搜索能力。

表 12 当前最终系统冻结子集评测结果（22 条复杂查询，184 篇真值论文）

模式	Precision	Recall	F1	最终真值论文数	状态
FAST	0.0842	0.0924	0.0680	14	已完成冻结离线评测
DEEP	0.0797	0.0940	0.0641	15	已完成冻结离线评测

12. 运行效率与结构化输出验收

冻结离线效率报告显示, FAST 在 22 条查询上共发生 74 次 LLM 调用, 平均 3.36 次/查询, 平均 Token 为 7,930/查询, 平均离线重放时延为 14.1 s; DEEP 共发生 109 次 LLM 调用, 平均 4.95 次/查询, 平均 Token 为 11,834/查询, 平均离线重放时延为 22.0 s。由于该组数据来自冻结产物的离线缓存重放, 物理网络请求为 0, 因此只能用于比较两种模式的相对计算开销, 不能作为真实生产 API 成本。

在真实 OpenAlex 与 DeepSeek 真实在线运行抽样中, FAST 已完成 5 条查询、5/5 成功, 平均 OpenAlex 物理调用约 10.8 次/查询, 平均 LLM 调用约 8.8 次/查询, 平均 Token 约 18,211/查询, 平均墙钟时延 (wall-clock latency, 即从请求开始到结果返回的实际等待时间) 约 58.2 s, P90 约 62.6 s。DEEP 的真实在线运行抽样受到 OpenAlex HTTP 429 请求频率限制影响, 仅部分查询完整成功, 因此其在线数据仅用于工程诊断, 不作为正式效率结论。

表 13 真实在线环境的运行效率抽样

模式	OpenAlex 调用/查询	LLM 调用/查询	Token 消耗/查询	平均时延	P90	说明
FAST	10.8	8.8	18,211	58.2 s	62.6 s	5/5 查询完整成功, 标题完整率 100%
DEEP	12.5	11.0	24,124	约 79.2 s	—	仅部分查询完整成功, 受 OpenAlex 限流影响, 仅作工程诊断

表 13 用于补充说明真实网络环境下的执行成本。FAST 的在线抽样能够完整反映 OpenAlex 物理请求和大语言模型调用带来的墙钟开销; DEEP 的抽样受到外部接口限流影响, 样本不足, 因此不作为正式性能结论。本文据此将离线重放指标用于可复现的模式对比, 将在线抽样用于部署成本诊断, 避免把缓存命中条件下的时延误写为真实生产时延。

结构化输出方面, 冻结产物中 FAST 共 233 条最终结果、DEEP 共 286 条最终结果, 当前结构化数据模式校验均为 100%, 且缺失标题数为 0。作者、年份、来源、DOI/OpenAlex ID 完整性及相关性解释出现率尚未形成逐字段可追溯审计产物, 因此本文不作未经测量的完整性声明。这种“测量到什么就报告什么”的口径与系统可审计设计保持一致。

13. 失败分析与多源召回诊断

当前系统的主要性能上限仍来自候选覆盖。多源诊断在相同的 89 个冻结子查询上对 Semantic Scholar 进行补充探针 (即不改变默认生产链路、仅用于测量数据源互补性的诊断检索): OpenAlex 当前查询组合命中 22 篇真值论文, Semantic Scholar 在此基础上发现 13 篇 OpenAlex 未命中的新增真值论文, 且增益集中在少数包含大量具体学术名称或用户用词与论文用词不一致的复杂查询。这一结果说明, **数据源互补性**具有进一步提升召回的潜力。

图 8 说明了不同学术数据源之间存在可利用的召回互补性。横轴对应冻结查询编号, 蓝色柱表示 OpenAlex 已命中的真值论文数, 绿色柱表示 Semantic Scholar 在相同子查询上新增发现的真值论文数; 新增结果并非均匀分布, 而是集中在少数包含具体模型/数据集名称或用户用词与论文用词不一致的查询上, 其中查询 6 单独新增 9 篇真值论文, 是最主要的增益来源。这意味着多源检索更适合作为有条件触发的补充召回策略, 而不是对所有查询无差别增加接口调用。

然而, 该探针属于诊断实验, 尚未经过与 FAST/DEEP 相同的生产集成、成本控制与正式评测, 因此当前版本不将 Semantic Scholar 写入默认生产后端。后续若继续优化, 应优先验证多源候选融合能否在可控 API 成本下稳定提升最终 F1, 再决定是否进入正式链路; 相较之下, 继续无边界增加精排模型规模的优先级较低, 因为未进入候选池的论文无法由精排器恢复。




图 8 多源召回诊断中的 Semantic Scholar 增量。对相同冻结子查询进行补充检索时，Semantic Scholar 在 OpenAlex 已命中的 22 篇真值论文之外新增发现 13 篇真值论文，增益集中在少数包含具体学术名称或存在表述用词不一致的复杂查询。该结果属于诊断实验，不代表 Semantic Scholar 已进入默认生产链路。

(三) 任务实施计划和风险分析

1. 实施任务

实施工作按照“基线与评测、查询规划与召回、综合精排与迭代检索、系统集成与复现、材料与演示”五类模块组织。表中仅列出各模块的主要任务与验收重点，用于说明个人在算法、评测、工程实现和材料整理等环节承担的完整工作范围，并以自动化测试、冻结评测和可复现产物降低单人开发中的自检偏差。

表 14 实施任务与验收要点

工作模块	主要任务	验收要点
基线与评测	建立词法基线、统一评测口径、论文身份对齐与自动评测框架	指标定义一致，评测数据可复现
查询规划与召回	复杂查询解析、子查询分解、联想词/具体学术名称补充、OpenAlex 召回与候选去重	查询可执行，候选来源可追溯
综合精排与迭代检索	大语言模型综合精排、确定性精排对照、证据引导二轮检索	排序结果可解释，迭代查询可追溯
系统集成与复现	FAST/DEEP 统一引擎、响应缓存、检索执行轨迹、结构化输出与复现审计	离线重放稳定，结构化结果可校验
材料与演示	Web 前端、评测仪表板、技术文档与演示材料	展示结果与同一检索引擎一致

2. 工程风险与控制

项目面临的主要工程风险包括外部 API 配额、模型非确定性、候选覆盖不足与评测口径漂移（即指标定义、数据版本或计数规则在不同实验间发生变化）。针对 API 配额，系统采用响应缓存、重复查询过滤、预算上限与断点恢复；针对模型非确定性，查询规划计划与正式评测结果均可冻结重放，并通过提示词与配置版本哈希（hash）固化条件；针对候选覆盖不足，系统保留联想词/具体学术名称召回与多源诊断接口；针对评测口径漂移，系统冻结评测语料版本指纹，并严格区分原始召回、精排候选池与最终输出三个阶段的指标。

四、参考资料

- [1] Y. He, H. Jin, C. Wu, H. Lu, et al. PaSa: An LLM Agent for Comprehensive Academic Paper Search. In *Proceedings of ACL 2025*, 2025.
- [2] L. Wang, et al. Synergistic Interplay between Search and Large Language Models for Information Retrieval. In *Proceedings of ACL 2024*, 2024.
- [3] SPAR: Scholar Paper Retrieval with LLM-based Agents for Enhanced Academic Search. *arXiv:2507.15245*, 2025.
- [4] J. Huang, et al. Knowledge-Aware Query Expansion with Large Language Models for Textual and Relational Retrieval. In *Proceedings of NAACL 2025*, 2025.
- [5] H. Yao, et al. LLM-QE: Improving Query Expansion by Aligning Large Language Models with Ranking Preferences. 2024.
- [6] MILL: Mutual Verification with Large Language Models for Zero-Shot Query Expansion. *arXiv:2310.19056*, 2024.
- [7] SciRAG: Adaptive, Citation-Aware, and Outline-Guided Retrieval and Synthesis for Scientific Literature. *arXiv:2511.14362*, 2025.
- [8] R. Nogueira, et al. Navigation-based candidate expansion and pretrained language models for citation recommendation. *Scientometrics*, 125(3):2491–2513, 2020.
- [9] OurResearch. OpenAlex: A free, fully open catalog of the global research system. <https://openalex.org>.
- [10] Towards Optimizing a Retrieval Augmented Generation using Large Language Model on Academic Data. *arXiv:2411.08438*, 2024.
- [11] ByteDance Seed. PaSa: An LLM Agent for Comprehensive Academic Paper Search — project repository and RealScholarQuery dataset description. <https://github.com/bytedance/pasa>, accessed 2026-09-01.
- [12] J. Bragg, M. D’Arcy, N. Balepur, et al. AstaBench: Rigorous Benchmarking of AI Agents with a Scientific Research Suite. In *ICLR 2026*, 2026.
- [13] Allen Institute for AI. AstaBench evaluation framework and PaperFindingBench task. <https://github.com/allenai/asta-bench>, accessed 2026-09-01.
- [14] Allen Institute for AI. Semantic Scholar Product: Search, TLDRs, Research Feeds and Alerts. <https://www.semanticscholar.org/product>, accessed 2026-09-01.
- [15] ResearchRabbit. Features: literature discovery, adaptive recommendations and interactive research maps. <https://www.researchrabbit.ai/features>, accessed 2026-09-01.
- [16] Consensus. Research Agent: multi-step academic search, citation crawling, DOI/author search and similar-paper tools. <https://help.consensus.app/en/articles/12641232-research-agent>, accessed 2026-09-01.
- [17] Consensus. Deep Review: sub-question decomposition and targeted literature searches. <https://help.consensus.app/en/articles/11740827-how-to-use-deep-review>, accessed 2026-09-01.
- [18] Elicit. Research Agent and scientific research workflows. <https://elicit.com/>, accessed 2026-09-01.