

科研场景下复杂学术查询的智能论文搜索与推荐系统

——eZScholar 智能学术检索 Agent

项目提案与实施方案（技术方案分册）

参赛团队

2026 年 8 月

目录

1	项目概况	3
1.1	项目背景与问题定义	3
1.2	已有基础与研究积累	3
1.3	项目目标与价值	4
1.4	场景分析与应用前景	5
1.5	资源需求	5
2	项目规划	6
2.1	总体技术路线	6
2.2	项目里程碑	7
2.3	技术创新点	8
2.4	与现有工作的差异化	9
3	实施方案	9
3.1	系统总体架构	9
3.2	技术可行性分析	10
3.3	关键技术细节	10
3.3.1	查询理解与规划	10
3.3.2	多路召回与缓存	11
3.3.3	综合精排与证据链	11
3.3.4	预算控制	11
3.3.5	结构化输出与归纳	11
3.4	评测数据构建与身份对齐	11
3.5	评测方法与现状	12
3.6	官方冻结评测与运行效率	14
3.7	实施计划与团队分工	15
3.8	前端页面规划	16
3.9	风险分析与应对	16

3.10 预期成果与交付物	16
4 参考资料	17

1 项目概况

1.1 项目背景与问题定义

本项目参加 2026 年中国研究生人工智能创新大赛（华为赛题三《科研场景下复杂学术查询的智能论文搜索与推荐》）。赛题要求参赛队伍构建能够理解复杂学术查询、自主完成多轮检索、输出结构化高质量结果的智能论文搜索与推荐系统。评测综合考察检索质量（F1，占 70%）、运行效率（占 20%）与结构化输出（占 10%）三个维度，既考核算法的检索精度，也考核系统的工程能力与可复现性。

在科研活动中，文献检索是最基础也是最耗时的工作之一。研究人员面对的是一个规模庞大且仍在快速增长的全球知识网络：以开放学术目录 OpenAlex 为例，其已收录超过 2.4 亿篇学术成果，涵盖期刊论文、专著、数据集、学位论文与预印本，并依托 Crossref、ORCID、ROR 等权威来源每日增量更新。信息过载与检索工具能力不足之间的矛盾日益突出，“找得全、找得准、找得快”已成为科研用户的刚性需求。

传统学术搜索引擎（如 Google Scholar、Semantic Scholar）对**短查询**、**关键词式查询**表现良好，但对**复杂学术查询**——即由多个研究侧面、限定条件与隐性约束构成的自然语言长句——召回质量显著下降。经过对真实科研查询的分析，这类复杂查询普遍具备以下特征：

- **语义复合**：一个查询同时包含研究对象、研究方法、应用场景、对比基线等多个维度，难以用单一关键词覆盖；
- **术语漂移**：查询使用的口语化词汇与目标论文标题、摘要中的学术术语重叠度低，直接检索命中困难；
- **隐含约束**：用户往往隐含“该领域代表性工作”“近三年”“与某方法形成对比”等未明确说出的要求；
- **结果组织**：用户不仅需要论文列表，更期望获得按主题组织的结构化归纳与可解释的证据支撑。

2025 年，字节跳动研究团队在 ACL 2025 发表的 *PaSa* ([1]) 正式提出这一挑战，并构建了面向真实场景的基准数据集 **RealScholarQuery**——由 50 条 AI 研究者真实提出的细粒度科研查询构成，答案由专业标注员逐一确认。实验结果显示，即便是 GPT-4o 配合 Google 检索改写的强基线，在 RealScholarQuery 上的 Recall@20 也比专门训练的 PaSa-7B 检索 Agent 低 37.78%。这一结果表明：**复杂学术查询的检索问题并未被通用工具解决，亟需专门的检索智能体**，而这正是本项目的切入点。

1.2 已有基础与研究积累

本项目并非从零起步。团队此前完成了可迁移的工程可信智能体架构 eZmanbo（电子元器件智能选型与风险评估 Agent），并将其验证过的核心机制——统一中间表示、约束解析、多路召回、评分门禁、硬约束校验、证据链、工具编排、缓存降级——迁移改造为

学术检索 Agent **eZScholar**（项目代号 ScholarTrace），已在真实服务器完成原型开发与多轮评测：

- **统一核心对象**：QueryIR（查询中间表示）、SubQuery（子查询）、PaperIdentity（论文身份）、PaperEvidence（证据链）、SearchTrace（执行轨迹）、RankResult（排序结果）、RunReport（运行报告），所有环节以结构化对象流转；
- **先宽后窄两阶段 Agent 流程**：Round0 查询解析 → Round1 宽召回 → Round2 引文扩展 → Round3 精排清理 → 早停决策；
- **免 Key 学术 API 适配**：OpenAlex 主召回、Crossref 身份对齐、Semantic Scholar 引文推荐、Unpaywall 开放获取、arXiv 预印本、OpenCitations 引文图；
- **完整评测阶梯**：B0（词法基线）→ B1（查询理解 + 子查询）→ B2（引文扩展）→ B3（LLM 精排）→ B4（缓存 + 预算早停）→ FULL 全链路，统一评测框架；
- **评测数据对齐**：基于 PaSa RealScholarQuery 基准，gold 论文按 OpenAlex ID / DOI / 归一化标题三重匹配对齐，避免同一论文多条记录导致的虚增。

截至本提案撰写时，系统已完成 50 条 RealScholarQuery 全量离线评测（OpenAlex 口径）：**平均 F1 = 0.0774，召回率 R = 0.0950，精确率 P = 0.1042**；其中 26 条查询 F1 > 0，16 条 F1 ≥ 0.1，最高单条 F1 = 0.370。与 B0 词法基线（平均 F1 = 0.0095）相比提升超过 8 倍，验证了”查询理解 + 子查询分解”作为第一技术杠杆的路线正确性。

1.3 项目目标与价值

本项目的总体目标是：**构建一个面向科研场景的复杂学术查询智能搜索与推荐系统**，通过”查询理解 → 查询规划 → 多路召回 → 质量门禁 → 综合精排 → 迭代搜索 → 证据输出 → 预算控制”的完整链路，将复杂自然语言查询转化为高质量、可溯源、结构化的学术论文检索结果，并满足比赛对**检索质量（F1）、运行效率、结构化输出**三方面权重的综合要求。

表 1：比赛评测权重构成与项目应对策略

评测维度	权重	项目应对
检索质量（F1）	70%	查询理解 + 子查询分解 + LLM 精排 + 引文扩展
运行效率	20%	缓存复用、预算早停、分层 LLM Router、并发限流
结构化输出	10%	统一 Schema、证据链、结构化归纳展示

项目价值体现在三个层面：

1. **对科研用户**：显著降低文献调研成本，将”检索”从关键词匹配升级为”研究问题的结构化求解”，让研究者把时间投入到真正的科研创造上；
2. **对比赛评测**：以冻结数据、可复现评测、可审计轨迹满足竞赛对公平性与可信性的硬性要求，评测口径全程透明可追溯；

3. **对技术体系**：沉淀一套可迁移的”领域知识获取 + 智能体工具编排 + 预算控制”工程范式，未来可复用到智能问答、知识服务等多个方向。

1.4 场景分析与应用前景

从应用场景看，复杂学术查询搜索系统至少可服务于三类用户：

- **科研新手**：面对陌生研究方向时，需要”研究问题 → 代表工作 → 方法谱系”的引导式检索，帮助快速建立领域地图；
- **资深研究者**：需要针对具体方法做系统性调研与对比，关注方法演进的引用链条与相关工作边界；
- **科研管理人员**：需要按主题聚合文献并生成结构化概览，用于学科布局、方向评估与决策支持。

三种场景对”检索质量 + 结构化归纳 + 可解释证据”的需求是共通的，这进一步支撑了本项目的技术路线选择。

结合本赛题（华为赛题三《科研场景下复杂学术查询的智能论文搜索与推荐》）的考核要点，本项目的功能点映射关系如下：

- **查询理解与分解**：对应 Round0 查询解析与子查询规划，将复杂长句拆解为可执行的检索单元；
- **自主检索迭代**：对应 Round1 多路召回与 Round2 引文扩展，系统可在无人干预下自主完成多轮检索；
- **综合排序**：对应 Round3 LLM 精排，综合语义相关度、证据强度与约束满足度给出最终排序；
- **结构化展示与归纳**：对应证据输出层的查询摘要、论文分组与总体结论，输出可直接用于文献综述；
- **对接学术数据库**：对应 OpenAlex / Crossref / S2 等免 Key 学术 API 的适配层；
- **成本控制**：对应预算早停与缓存复用机制，保证系统在有限资源下稳定运行。

1.5 资源需求

项目运行不依赖自建大规模论文全文库，主要资源由学术检索接口、大语言模型推理接口、常规计算环境、缓存存储与稳定网络组成，资源需求如下：

表 2: 资源需求与用途

支持类别	主要内容	用途
学术数据接口	OpenAlex 等开放学术检索接口	论文召回、论文身份及基础元数据获取
模型推理能力	大语言模型 API (DeepSeek)	复杂问题理解、查询规划、候选语义判断
计算与存储	常规 CPU 服务器或个人计算机、实验缓存空间	运行检索流程、保存响应缓存与评测产物
开发环境	Python 运行环境及版本管理工具	系统开发、自动评测与实验复现
网络环境	稳定的外部 API 访问能力	在线学术检索和模型调用

2 项目规划

2.1 总体技术路线

项目采用以查询理解为第一杠杆、以多路召回为覆盖基础、以 LLM 精排为质量核心、以预算控制为工程约束的四层技术路线，构成”先宽后窄”的检索闭环：

1. **Round0 查询解析**：将复杂自然语言查询解析为结构化 QueryIR（研究主题、方法、应用、约束、年限等字段），再由规划器生成多个子查询；
2. **Round1 宽召回**：对规划子查询执行多路召回（OpenAlex 主召回 + 联想词专名召回 + 免 Key API 补充），最大化候选池覆盖；
3. **Round2 引文扩展**：基于种子论文的引用与被引关系沿引文图扩展 (Semantic Scholar 或 OpenCitations)，捕获主题接近但词面不重叠的工作；
4. **Round3 精排清理**：LLM 综合精排，输出 score / label / reason 与证据链，动态截断并过滤不相关候选；
5. **早停与预算控制**：依据预算上限（API 调用数、token 数）与高相关收敛信号决定是否提前终止，控制运行成本。




图 1: eZScholar 系统架构与”先宽后窄”检索闭环。查询经结构化解析后生成多个子查询与联想词专名子查询（创新点 1），依次执行多源召回、词法粗筛、引文扩展与大语言模型（LLM）综合精排，最终输出带证据链的结构化推荐。蓝色模块为本项目创新点；LLM 指大语言模型，OpenAlex 与 Semantic Scholar 为两个主流开放学术文献数据源。

表 3: B0-FULL 实验阶梯与功能点对齐

实验阶梯	功能定位	对齐赛题功能点
B0 词法基线	直接查询 OpenAlex + 词法排序	检索能力（下限对照）
B1 查询理解	QueryIR + 子查询分解 + 联想词	查询理解 / 分解
B2 引文扩展	S2 / OpenCitations 引文图	自主检索迭代
B3 LLM 精排	综合相关度 + 证据链	综合排序
B4 缓存预算	磁盘缓存 + 预算早停	成本控制
FULL 全链路	多轮扩展 + 早停决策 + 归纳	结构化展示 / 全功能点

表 4: FAST 与 DEEP 双模式定位

模式	主要流程	定位
FAST	Round-1 查询规划 → OpenAlex 召回 → 去重与候选池 → LLM 精排 → 结构化输出	默认竞赛评测模式，
DEEP	FAST + Round-1 Observation → 二轮 Planner → Follow-up 检索 → Merge → 精排	复杂问题的可选深度模式

2.2 项目里程碑

依据比赛时间窗（报名 8 月 25 日截止、赛题提交 9 月 11 日），项目划分为三个阶段：

- **第一阶段——基线验证（已完成）：**完成仓库搭建、B0 词法基线评测、核心数据结构定义、评测框架构建、挑战查询整理；
- **第二阶段——能力建设（已完成）：**完成查询理解、多路召回、引文扩展、LLM 精排、全链路集成与 50 条基准全量评测；

- **第三阶段——冻结与交付（进行中）：**冻结评测数据集、对齐 gold 身份、FULL 冻结验证、复现包构建、前端页面开发与答辩准备。

2.3 技术创新点

创新点 1：联想词专名召回机制。针对” 查询词汇与论文标题零重叠” 这一核心召回失败根因（实测占 184 篇真值论文未命中的 88%），本系统在规划阶段要求大语言模型（LLM）提炼代表性论文标题关键词（联想词），以独立高优先级子查询执行。实测该查询公式化策略使独立真值论文召回量由基线 22 篇提升至 25 篇（+3），配合提示词优化进一步增至 26 篇；叠加 Semantic Scholar 多源召回后，在 OpenAlex 之上额外新增 13 篇真值论文（+7.1%）。离线消融进一步表明，关闭联想词候选的保送机制（assoc safepass）不改变原始召回，却使进入精排池的独立真值论文由 24 降至 13、最终独立真值论文由 16 降至 11、平均 F1 由 0.0618 降至 0.0485——该机制的作用不是制造更多召回，而是保护联想词已发现的候选不被词法粗筛提前丢弃。该机制以轻量方式复现了 PaSa 中”LLM 先验回忆” 的关键作用，且不依赖复杂的强化学习训练。

表 5：查询公式化与迭代检索的召回增益（真值论文数为去重后的独立命中数；真值论文即基准中人工标注的正确论文）

优化环节	策略	独立真值论文数	增量
查询公式化	初始基线	22	—
	追加联想词子查询	25	+3
	提示词优化	26	+1
证据引导迭代检索	单轮检索	25	—
	合并多轮检索	27	+2（2/22 查询）

创新点 2：统一中间表示与可审计执行轨迹。所有检索环节以 QueryIR / SubQuery / PaperIdentity / SearchTrace 等结构化对象流转，全程落盘可追溯，兼顾评测可复现性与证据链可解释性，为后续的失败归因与迭代优化提供了完整的观测基础。

创新点 3：基于边际检索收益的预算重分配。磁盘召回缓存跨实验复用、计划缓存（query → IR + 子查询）避免非确定性重复消耗、预算与 token 双层早停、LLM 失败自动降级，构建了可上线、成本可控的检索系统。在此基础上，阶段级追踪对每个检索阶段记录逻辑 API 调用、候选增量与目标论文命中，量化各阶段**边际收益**：受控实验中，无差别执行引文、参考与元数据扩展合计消耗 422 次逻辑调用却未带来任何新增命中，关闭后单查询逻辑调用由 511 降至 87，平均 F1 反而由 0.0528 提升至 0.0618（表 9）。系统据此将预算优先配置给直接检索与高价值查询规划，实现” 低成本不损质量” 的预算重分配，契合比赛对运行效率的考核。

创新点 4：双源引文扩展。有 Semantic Scholar Key 时走 Semantic Scholar（S2）引文链，无 Key 时自动切换 OpenCitations（COCI，无 Key 引文图），保证引文扩展在任何环境下均可运行，提升了系统的环境适应性与鲁棒性。

2.4 与现有工作的差异化

与 PaSa ([1]) 等代表性工作相比，本项目在以下三方面形成差异化：

- **轻量化与低成本**：PaSa 需要大规模合成数据训练与强化学习优化，而本系统采用免训练的提示工程方案，仅依赖通用 LLM API 与免 Key 学术数据源即可运行，更契合比赛对运行效率的约束；
- **强可审计性**：本系统以统一中间表示与 SearchTrace 轨迹记录每一次检索、扩展与精排决策，支持逐条失败归因，而 PaSa 类方法更侧重端到端效果，内部决策可解释性较弱；
- **工程可信优先**：本系统将缓存复用、预算早停、降级容错作为一等公民设计，保证在有限配额、网络抖动、模型不可用等现实约束下仍能产出稳定结果。

这种差异化定位使本项目在”检索效果 + 工程可信 + 成本可控”三个维度上取得平衡，符合赛事对综合性工程能力的要求。

3 实施方案

3.1 系统总体架构

系统总体架构如图所示（前端页面正在开发，插图位置预留）：

[插图预留位]

图 1：eZScholar 系统总体架构图（查询理解 → 查询规划 → 多路召回 → PaperIR → 质量门禁 → 精排 → 迭代搜索 → 证据输出 → 预算控制）。前端页面开发完成后替换为正式架构图。

系统由以下分层构成：

1. **接入层**：FastAPI 提供 `/search` 搜索接口与 `/health` 健康检查，支持 `b0-full` 多模式切换与 `summarize` 归纳开关；
2. **查询理解层**：解析器将自然语言解析为 QueryIR，规划器生成子查询规划与联想词；
3. **召回层**：多路召回适配器（OpenAlex / Crossref / S2 / arXiv / OpenCitations），磁盘缓存复用；
4. **门禁层**：质量门禁对候选进行词法粗筛与预算检查；
5. **精排层**：LLM Router 分层（fast 模型走解析与规划，strong 模型走精排），输出 `score / label / reason`；

6. 迭代搜索层：引文扩展 + 早停决策，形成多轮检索闭环；
7. 证据输出层：证据链构建 + 结构化归纳（查询摘要 + 论文分组 + 总体结论）；
8. 展示层：Web Demo（搜索框 + 模式选择 + 结果列表 + 分组视图 + 引文关系图）。

[插图预留位]

图 2：前端页面截图位（搜索界面 + 结构化结果展示 + 引文关系图）。Web 前端开发完成后替换为实际截图。

3.2 技术可行性分析

从数据条件看，OpenAlex 提供覆盖广泛的学术论文元数据与检索接口，可满足赛题的基础论文搜索、论文身份核验与候选获取需求；系统无需自建全文索引，显著降低存储、索引构建与维护成本。论文身份采用 DOI、OpenAlex ID、论文 ID 与规范化标题等多字段统一，支持跨查询去重、候选生命周期跟踪与评测匹配。

从算法条件看，复杂查询可拆分为查询理解、检索规划、候选召回、候选池构建、语义精排与结果整理等独立环节，LLM 负责固定规则难以完成的语义理解与规划，学术数据接口负责论文事实与候选集合，职责边界明确。项目已完成多轮冻结计划、缓存重放、检索预算消融、查询规划消融、精排稳定性审计与二轮检索实验，为最终系统集成提供了充分工程基础。

从效率条件看，阶段级诊断已证明大量扩展调用可以在不降低最终 F1 的情况下被移除（表 9）。正式系统保留缓存、预算上限、重复查询过滤与离线 replay 能力，并区分逻辑调用与物理 HTTP 请求，便于在竞赛环境中同时评估算法步骤与真实网络成本。

从工程条件看，系统已完成 FAST/DEEP 统一检索引擎、结构化输出、SearchTrace、冻结计划与响应缓存、Gold 泄漏检测与自动化测试；离线验收中 22 条冻结查询均可完成 cache replay，Round-2 实际执行 62 个 follow-up 查询、未超过配置的 66 次预算上限。

3.3 关键技术细节

3.3.1 查询理解与规划

查询解析器将原始查询映射为 QueryIR（research_topic / method / application / constraints / year_range 等字段）；规划器输出子查询列表，其中**联想词子查询不受 B1_MAX_SUBQUERIES=5 截断限制**，保证专名召回完整性。计划缓存以 PLANNER_VERSION 标识版本，配置变更后自动失效并重新规划，保证实验可复现。规划提示词经过多轮迭代，加入成功示例引导（如“InstructVideo human feedback”、“BitNet 1.58 bits”等典型专名），显著提升窄命中率。

3.3.2 多路召回与缓存

召回源通过配置 `recall_source` 动态选择 (`openalex / crossref / s2`)。OpenAlex 采用 `credits` 配额制 (约 1000 credits/天/IP)，系统通过并发上限 2、429 退避 (5-30s 六次重试) 与磁盘缓存 (`jsonl`) 三重机制控制配额消耗；计划缓存与召回缓存分离、跨实验复用，一次配额即可跑完全部对比实验。评测框架支持 `--skip-existing` 断点续跑与 `after_query` 逐条落盘，支持长时任务的可靠恢复。

3.3.3 综合精排与证据链

精排器对召回候选分批调用 LLM，输出相关度评分与理由，动态截断 (保留 `score ≥ 0.35` 的候选且保底 3 篇、上限 `top-k`)，失败时自动降级为词法排序。排序结果记录命中约束集合 (`RankResult.constraint_coverage`)，构建证据链，回答“为什么推荐这篇论文”，使结果可解释、可溯源。

3.3.4 预算控制

系统实现双层预算检查：`budget_max_api_calls` (召回与引文前的 API 调用预算) 与 `budget_max_tokens_per_query` (精排前的 token 预算)。超限时精排直接返回词法结果以节省 token。FULL 全链路中，早停决策综合预算剩余、轮数上限与高相关收敛信号 (`_high_relevance` 词法 PARTIAL+ 计数)，在质量与成本之间取得平衡。

3.3.5 结构化输出与归纳

为满足比赛对结构化输出的考核要求，系统设计了统一输出 Schema。每篇推荐论文的 `StructuredResult` 包含论文身份 (OpenAlex ID、DOI、标题、作者、年份、来源期刊)、相关度评分、相关度标签、推荐理由 (`evidence`) 与约束覆盖集合。当开启归纳开关时，系统进一步生成 `query_summary` (查询主题概述)、论文分组 (按方法/主题/应用聚类) 与总体结论，使用户能够直接获取一份结构化的文献调研报告，而非零散的论文列表。该输出设计以 JSON Schema 固化，前端页面可直接渲染，也便于评测程序自动校验字段完整性。

3.4 评测数据构建与身份对齐

为保证评测的公正性与可复现性，项目对基准数据的构建投入了专门工作。原始 `RealScholarQuery` 提供每条查询对应的 gold 论文清单，但原始记录多为标题或混合格式，直接用于检索匹配会产生严重偏差。为此，系统构建了三重身份对齐流程：

1. **OpenAlex 检索对齐**：以 gold 标题在 OpenAlex 中检索，取最高相关记录，记录 OpenAlex ID 与规范化标题；
2. **DOI 交叉验证**：对存在 DOI 的记录，通过 Crossref 元数据反向核对标题，消除同名异篇或异名同篇的歧义；

3. **归一化标题比对**: 对标题做大小写、标点、空白与停用词归一化后逐字符比对, 作为最终身份判定依据。

经该流程处理后的评测集, 每篇 gold 论文均持有唯一的 OpenAlex 身份标识, 系统在评测时只对候选池中的 OpenAlex ID 做集合匹配, 从而精确计算 F1 的命中集合, 避免因同一论文在数据库中的多条记录而重复计分。评测口径同时记录 OpenAlex (主口径) 与 Crossref (对照口径) 两套结果, 并在每条查询的轨迹中保留召回、精排、扩展各环节的逐项统计, 供失败分析与答辩举证。

3.5 评测方法与现状

评测基于 PaSa RealScholarQuery 基准 (50 条真实复杂查询), gold 论文按 OpenAlex ID / DOI / 归一化标题三重匹配对齐, 避免同一论文多记录造成的虚增。评测口径区分 OpenAlex (主) 与 Crossref (对照), 并记录每条查询的召回、精排滤除、API 错误归因, 形成完整的失败分析。

表 6: RealScholarQuery 50 条全量评测结果 (OpenAlex 口径)

指标	B0 词法基线	B1 查询理解	FULL 全链路
平均 F1	0.0095	0.0127	0.0774
召回率 R	0.100	0.133	0.0950
F1 > 0 查询数	2/20	2/15	26/50
最高单条 F1	—	—	0.370

注: B0/B1 为受配额限制的子集评测 (分别覆盖 20/15 条查询), FULL 为 50 条全量评测; 三个口径均不含生成式大语言模型精排, 可复现。全链路平均 F1 约为词法基线的 8.2 倍。




图 2: 全链路在 50 条查询上的逐条 F1 分布 (蓝色为 F1>0, 灰色为 F1=0)。可见多数查询仍为零命中 (召回覆盖不足是首要瓶颈), 少数查询取得较高 F1 (最高 0.37)。横轴为竞赛基准 PaSa RealScholarQuery 的 50 条真实复杂科研查询编号。

评测结论与失败归因：全链路在 50 条查询上平均 F1 达 0.0774，约为词法基线的 8.2 倍，但仍有 24 条查询 F1=0，召回仍是**第一瓶颈**。对 22 条已覆盖查询中的 184 篇真值论文逐篇归因：162 篇（88.0%）因词面与查询零重叠而**完全未进入候选池**，13 篇（7.1%）在词法粗筛阶段被**挤出**，9 篇（4.9%）在精排阶段被**降级**，**无任何假召回**。这一结论与 PaSa 论文”先解决召回覆盖、再优化排序”的判断高度一致，也验证了本系统失败归因框架的有效性。

进一步归类上述失败去向：其一，查询中的关键实体（方法名、数据集名、系统名）在目标论文标题中以别名或缩写形式出现，词面零重叠，构成**未召回**（88%）的主体；其二，查询描述的科研任务过于宽泛，子查询难以覆盖真值论文所在的具体子方向；其三，真值论文发表于较冷门会议或非英语文献，单一数据源元数据收录不全。针对第一类，**联想词专名召回**（独立真值论文召回由基线 22 提升至 25）与**多源召回**（Semantic Scholar 在 OpenAlex 之上额外新增 13 篇真值论文，+7.1%）已显著改善；针对第二类，需要更精细的子查询生成策略；针对第三类，可通过扩大召回源覆盖加以缓解。这一逐级归因的方法论，使后续优化始终有据可依，避免盲目调参。

表 7：失败去向归因（22 条已覆盖查询、184 篇真值论文；真值论文即基准中每条查询对应的人工标注正确论文）

失败类别	篇数	占比	发生阶段
未召回（词面零重叠）	162	88.0%	检索覆盖
词法粗筛挤出	13	7.1%	词法过滤
精排降级	9	4.9%	综合排序
合计（无假召回）	184	100%	—




图 3：Semantic Scholar 多源召回增益（逐查询对照）。OpenAlex 单独召回 22 篇真值论文，叠加 Semantic Scholar 后新增 13 篇（+7.1%）且与 OpenAlex 结果不相交，共 5 条查询受益。图中蓝色为各查询的 OpenAlex 召回量、绿色为 Semantic Scholar 新增量，其中查询 6 新增 9 篇（其目标论文含大量专名、词面与查询零重叠）。Semantic Scholar (S2) 为另一主流开放学术文献数据库与检索 API。

表 8: 精排器消融（冻结候选池、22 条查询，各精排器输出候选数量一致；均为确定性方法）

精排策略	类型	模型规模	宏平均 F1
大语言模型综合精排（生产）	生成式	—	0.0664
MiniLM 句向量打分器	轻量嵌入	22M	0.0598
BGE 精排器	嵌入精排	568M	0.0588
RRF 词频融合	无模型	—	0.0241




图 4: 大语言模型精排的随机性（7 条高覆盖查询、同一候选池 3 次重复重排）。同一输入重复精排，F1 出现明显波动（最大差 0.089），说明生成式精排的排序结果非确定；这要求评测以多次运行或缓存回放保证可复现。红点与蓝点分别为 3 次重排的 F1 下界与上界。

表 9: 低收益扩展阶段的受控消融（FULL 与 NO_CITATION 对比；历史冻结计划与响应缓存口径）

方案	平均 F1	逻辑 API 调用	结论
FULL（完整扩展链路）	0.0528	511	引文/参考/元数据扩展占用 422 次调用、零新增
NO_CITATION（关闭低收益扩展）	0.0618	87	成本下降约 83%，F1 反而提升

3.6 官方冻结评测与运行效率

在 50 条全量评测之外，项目依据竞赛复现要求构建了官方冻结评测集：从 RealScholarQuery 测试集冻结 22 条复杂查询(184 篇 paper-level Gold, corpus version 为 pasa_realscholar_test_b3b570411ce2399c), 统一数据文件、查询集合与 corpus fingerprint，避免不同阶段因数据版本或计数口径变化造成误判。FAST 与 DEEP 均采用 final-output-based 口径（以最终用户可见结果中的 Gold 命中计算 P/R/F1），retrieval-stage Gold 另行记录、不与 final Gold 混用：

表 10: S1 官方冻结评测结果 (22 条复杂查询, 184 篇 Gold)

模式	Precision	Recall	F1	final unique Gold	状态
FAST	0.0842	0.0924	0.0680	14	离线冻结评测通过
DEEP	0.0797	0.0940	0.0641	15	离线冻结评测通过

FAST 在冻结集上的平均 F1 高于 DEEP, 因此最终将 FAST 设为默认竞赛模式; DEEP 能执行证据引导的二轮检索并发现第一轮未覆盖论文 (Round-2 新增独立真值论文 2 篇, 62 个 follow-up 查询均在预算内), 故保留为复杂问题的可选深度检索能力。

在模型与检索接口余额恢复后, 系统完成了**真实在线冒烟评测** (真实 OpenAlex HTTP 与真实 DeepSeek 调用, 非缓存回放), 并区分逻辑 API 调用与物理 HTTP 请求:

表 11: 真实在线运行效率 (在线冒烟, 非回放)

模式	OpenAlex 调用/查询	LLM 调用/查询	Token/查询	平均时延 (ms)	P90 时延 (ms)	说明
FAST 在线	10.8	8.8	18,211	58,239	≈62,574	5/5 月
DEEP 在线	12.5	11.0	24,124	≈79,202	—	2/5 月

真实在线时延的主要来源是学术接口的物理往返与并发上限, 而非算法逻辑本身; 相比离线回放 (frozen 产物物理 HTTP 调用为 0), 在线时延反映真实部署成本。DEEP 在线冒烟受 OpenAlex 日配额限流影响仅 2/5 查询完整成功, 其数字仅作参考、不作为正式效率结论, 可在配额恢复后重跑补全。

3.7 实施计划与团队分工

表 12: 实施计划 (已执行的阶段以 ★ 标记)

阶段	时间	主要任务
S0 基线与评测 (★)	8/20-8/21	建仓、B0 基线、核心 Schema、评测框架、20 条挑战查询
S1 查询理解 (★)	8/20-8/24	Parser/Planner、子查询分解、联想词召回、B1 评测
S2 引文扩展 (★)	8/21-8/24	S2 / OpenCitations 双源引文、B2 评测、50 条全量
S3 精排与全链路 (★)	8/22-8/24	LLM 精排、FULL 全链路、早停决策、PaSa 全量评测
S4 前端与归纳 (★)	8/22	Web Demo、结构化归纳、引文关系图、轻量数据库
S5 比赛冻结	8/25-9/9	冻结评测集、对齐 gold、FULL 冻结验证、复现包
S6 答辩准备	9/9-9/11	材料整理、PPT、演示、专家分准备

团队分工 (拟): 系统架构与核心算法 (1 人)、评测与数据 (1 人)、前后端与展示 (1 人)、文档与答辩 (1 人)。

3.8 前端页面规划

为直观呈现系统的检索能力与结构化输出，项目规划了一个简洁的 Web 展示页面，包含四个核心区域：

- **搜索入口**：提供查询输入框、模式选择（快速/深度）、归纳开关，支持输入后一键检索；
- **结果列表**：以卡片形式展示推荐论文，每张卡片包含标题、作者、年份、来源、相关度评分与推荐理由，点击可查看详情；
- **结构化归纳区**：展示查询摘要、论文分组与总体结论，帮助用户快速把握检索结果的整体结构；
- **引文关系图**：以可视化方式呈现核心论文与扩展论文之间的引用/被引关系，使用户直观理解检索的扩展路径。

该前端页面正在开发中，本节图 2 预留了页面截图的位置，页面完成验收后将替换为实际截图。前端采用轻量技术栈，通过 REST 接口调用后端服务，不引入额外的计算负担，保证演示环境的轻量化部署。

3.9 风险分析与应对

- **API 配额风险**：OpenAlex 每日配额有限，可能影响大规模评测。应对：磁盘缓存复用、本地 + 服务器双 IP 并行、优先跑关键实验；
- **模型非确定性风险**：LLM 输出存在随机性，影响可复现评测。应对：计划缓存 + 冻结计划 + 温度设为 0，以缓存回放保证离线复现；
- **召回覆盖风险**：部分 gold 论文与查询词面零重叠。应对：联想词专名召回 + 引文图扩展双通道；
- **时间风险**：提交截止 9 月 11 日。应对：冻结时间窗前置到 9 月 9 日，为答辩预留缓冲。

3.10 预期成果与交付物

项目计划交付的成果物包括：

- **可运行的检索系统**：完整实现的 eZScholar 后端服务（FastAPI 接口）与前端 Demo，支持 b0-full 多模式切换与结构化归纳展示；
- **冻结评测包**：冻结的 50 条 RealScholarQuery 评测集、gold 论文身份对齐表、评测脚本与复现说明，保证结果可复现、可审计；
- **结构化输出**：统一 JSON Schema 定义、前端渲染模板与字段完整性校验工具；
- **技术文档**：本提案、技术方案说明、评测报告、答辩演示材料；
- **证据链与执行轨迹**：SearchTrace 完整执行日志，可追溯每篇推荐论文的召回来源、扩展路径与精排理由。

这些交付物共同构成一个“可用、可复现、可解释、可答辩”的完整参赛方案，既满足比赛评测要求，也具备真实的科研应用价值。

4 参考资料

以下为项目技术与方案设计的权威支撑文献：

表 13：核心参考论文

编号	文献
[1]	He Y, et al. PaSa: An LLM Agent for Comprehensive Academic Paper Search. <i>ACL 2025</i> . 提供 RealScholarQuery 基准与智能体式学术检索范式。
[2]	Wang L, et al. Synergistic Interplay between Search and Large Language Models for Information Retrieval (Inter). <i>ACL 2024</i> . 检索与 LLM 协同迭代框架。
[3]	SPAR: Scholar Paper Retrieval with LLM-based Agents for Enhanced Academic Search. <i>arXiv:2507.15245</i> . LLM 智能体学术检索增强。
[4]	Huang J, et al. Knowledge-Aware Query Expansion with Large Language Models for Textual and Relational Retrieval (KAR). <i>NAACL 2025</i> . 查询扩展与结构化关系利用。
[5]	Yao H, et al. LLM-QE: Improving Query Expansion by Aligning Large Language Models with Ranking Preferences. 面向排序偏好的查询扩展。
[6]	MILL: Mutual Verification with Large Language Models for Zero-Shot Query Expansion. <i>arXiv:2310.19056</i> . 零样本查询扩展互验。
[7]	SciRAG: Adaptive, Citation-Aware, and Outline-Guided Retrieval and Synthesis for Scientific Literature. <i>arXiv:2511.14362</i> . 引文感知的学术检索与综合。
[8]	Nogueira R, et al. Navigation-based candidate expansion and pretrained language models for citation recommendation. <i>Scientometrics</i> 125(3), 2020. 引文图导航候选扩展 + 预训练模型重排。
[9]	OpenAlex 项目文档与 API 文档. <i>openalex.org</i> . 2.4 亿 + 学术成果开放元数据目录，CC-0 许可。
[10]	Towards Optimizing a Retrieval Augmented Generation using Large Language Model on Academic Data. <i>arXiv:2411.08438</i> . 学术领域 RAG 优化。

上述文献为项目设计提供了直接依据：

- 基准选择与评测口径：[1] 的 RealScholarQuery；
- 查询理解与子查询分解：[2] 的检索-LLM 协同、[4] 的查询扩展；
- 引文扩展与候选放大：[8] 的引文图导航扩展、[7] 的引文感知检索；
- 精排与质量门禁：[5]、[6] 的 LLM 排序偏好与互验；
- 工程基础设施：OpenAlex 开放学术数据 [9] 与免 Key API 生态。

参考文献

- [1] Y. He, H. Jin, C. Wu, H. Lu, et al. PaSa: An LLM Agent for Comprehensive Academic Paper Search. In *Proceedings of ACL 2025*, 2025.
- [2] L. Wang, et al. Synergistic Interplay between Search and Large Language Models for Information Retrieval. In *Proceedings of ACL 2024*, 2024.
- [3] SPAR: Scholar Paper Retrieval with LLM-based Agents for Enhanced Academic Search. *arXiv:2507.15245*, 2025.
- [4] J. Huang, et al. Knowledge-Aware Query Expansion with Large Language Models for Textual and Relational Retrieval. In *Proceedings of NAACL 2025*, 2025.
- [5] H. Yao, et al. LLM-QE: Improving Query Expansion by Aligning Large Language Models with Ranking Preferences. 2024.
- [6] MILL: Mutual Verification with Large Language Models for Zero-Shot Query Expansion. *arXiv:2310.19056*, 2024.
- [7] SciRAG: Adaptive, Citation-Aware, and Outline-Guided Retrieval and Synthesis for Scientific Literature. *arXiv:2511.14362*, 2025.
- [8] R. Nogueira, et al. Navigation-based candidate expansion and pretrained language models for citation recommendation. *Scientometrics*, 125(3):2491–2513, 2020.
- [9] OurResearch. OpenAlex: A free, fully open catalog of the global research system. <https://openalex.org>, 2025.
- [10] Towards Optimizing a Retrieval Augmented Generation using Large Language Model on Academic Data. *arXiv:2411.08438*, 2024.